

Análise Estatística do Desempenho Escolar no Brasil: Evidências do SAEB 2023

Engenharia de Software - Probabilidade e Estatística - 2025.2

Anderson Ramos Monteiro Dias
Pedro Borges Minchev
Tiago Sales Ribeiro
Victor Rangel Tasse Magalhães

1 Introdução

O Sistema de Avaliação da Educação Básica (SAEB) é a principal ferramenta de monitoramento da qualidade educacional brasileira. Este relatório apresenta uma análise estatística descritiva baseada nos microdados do SAEB 2023, com foco nos alunos concluintes do Ensino Médio (3^a e 4^a séries). Utilizando uma Amostragem Aleatória Simples (AAS) de 50.000 observações, o objetivo central deste estudo é investigar os determinantes do desempenho escolar, avaliando descritivamente as seguintes hipóteses:

- **H1 (Interdisciplinaridade):** A proficiência em Língua Portuguesa (LP) tem uma relação linear positiva com a proficiência em Matemática (MT).
- **H2 (Fator Socioeconômico):** O nível socioeconômico (INSE) do aluno impacta positivamente sua nota em Matemática.
- **H3(Incerteza em MT):** A incerteza estatística da nota (Erro Padrão) em Matemática é inversamente relacionada à proficiência do aluno.

As análises a seguir confirmam descritivamente todas as quatro hipóteses. Os resultados indicam que o desempenho em Português e o nível socioeconômico são preditores positivos do desempenho em Matemática. Além disso, a análise revela uma forte relação negativa entre o erro padrão e a proficiência; alunos com notas mais baixas tendem a ter medições estatisticamente mais incertas, sendo esta a correlação mais forte encontrada no estudo.

1.1 Metodologia de Amostragem

Dada a magnitude da base original do SAEB (TS_ALUNO_34EM.csv), que censita milhões de estudantes, optou-se por trabalhar com uma amostra representativa. Foi realizada uma **Amostragem Aleatória Simples (AAS) de 50.000 observações**, garantindo que cada aluno da base original tivesse a mesma probabilidade de ser selecionado. Para assegurar a reprodutibilidade científica deste estudo, fixou-se a semente de aleatoriedade (`set.seed(123)`). Este tamanho amostral ($n=50.000$) é robusto o suficiente para minimizar erros padrões e garantir alta confiabilidade nas estatísticas realizadas

2 Análise Descritiva

Nesta seção, exploramos o perfil dos estudantes e a distribuição de suas notas.

2.1 Taxa de Participação

Inicialmente, verificamos a taxa de participação efetiva dos alunos na prova de Matemática. Consideramos como “Ausente/Sem Nota” aqueles que possuem valor nulo (NA) na variável de proficiência.

Table 1: Participação na Prova da SAEB 2023

Situação	Frequência (%)
Ausente/Sem Nota	27.1
Presente	72.9

Na amostra de 50.000 alunos, observa-se que 13552 alunos (27.1%) não possuem registro de nota para a prova e nesse caso faltaram na prova. As análises de desempenho subsequentes consideram apenas os alunos com notas válidas.

2.2 Análise Univariada

Antes de testar as hipóteses, é fundamental entender a distribuição das principais variáveis quantitativas do estudo. A tabela a seguir (“Tabelão”) apresenta um resumo das métricas de tendência central (Média, Mediana, Moda) e de dispersão (Variância, Desvio Padrão, Mínimo, Máximo) para as variáveis numéricas de interesse.

Table 2: Tabela Resumo de Estatísticas Descritivas (Variáveis Quantitativas)

Variável	Média	Mediana	Moda	Variância	Desvio Padrão	Mínimo	Máximo
Proficiência (Língua Portuguesa)	273.57	276.84	391.88	2602.85	51.02	141.85	408.73
Proficiência (Matemática)	268.23	264.70	225.70	2215.83	47.07	167.46	451.24
INSE (Nível Socioeconômico)	4.86	4.87	4.87	0.88	0.94	2.12	7.62
Erro Padrão (LP)	22.79	21.30	29.75	19.00	4.36	16.42	41.89
Erro Padrão (MT)	31.71	32.11	37.70	62.39	7.90	11.24	63.93
Idade (Estimativa Numérica)	17.75	18.00	18.00	0.74	0.86	16.00	21.00

2.2.1 Interpretação da Tabela:

A tabela de estatísticas descritivas revela pontos importantes sobre as variáveis centrais.

- **Proficiência (LP e MT):** As proficiências em Língua Portuguesa e Matemática apresentam distribuições muito simétricas. Observa-se que a Média e a Mediana são quase idênticas (ex: LP Média 273.57 vs. Mediana 276.84). Isso indica que as notas se distribuem de forma equilibrada em torno do centro, sem uma “cauda” longa de notas muito baixas ou muito altas distorcendo a média. O Desvio Padrão (DP) de aproximadamente 51 pontos em LP e 47 em MT, confirmado pela alta Variância (≈ 2603 e ≈ 2216 , respectivamente), mostra que há uma dispersão considerável nos resultados dos alunos.
- **INSE: O Nível Socioeconômico (INSE)** segue o mesmo padrão, com Média (4.86) e Mediana (4.87) muito próximas, indicando uma distribuição também simétrica.
- **Idade:** A Idade (Estimativa Numérica) é a única variável que mostra uma leve assimetria. A Moda (18) e a Mediana (18) indicam que 17 anos é a idade mais frequente e central. Contudo, a Média (17.75) é puxada para cima pela presença de alunos mais velhos (18, 19, 20+ anos), o que configura uma leve assimetria à direita.

3 Análise Bivariada: Correlação e Regressão

Esta seção investiga a relação entre duas variáveis (análise bivariada). O objetivo é descrever como as variáveis quantitativas se comportam juntas dentro da nossa amostra, usando Correlação de Pearson e Regressão Linear Simples.

3.1 Análise H1 - A Relação entre Leitura e Matemática

Investigamos se o desempenho em Língua Portuguesa (variável independente) pode explicar o desempenho em Matemática (variável dependente).

3.1.1 Resultados Obtidos




Figure 1: Relação entre Proficiência em LP e MT

O **Coefficiente de Correlação (r)** foi de **0.5668**. Este valor indica uma correlação linear positiva moderada entre as duas proficiências, ou seja, uma pouca dependência entre essas duas variáveis mas que essa “dependência” é crescente. Para quantificar essa relação, ajustamos o seguinte modelo de regressão linear:

$$Nota_{MT} = 125.15 + 0.52 \cdot (Nota_{LP})$$

3.1.2 Interpretação dos Resultados

Poder Explicativo (R^2): O Coeficiente de Determinação foi de $R^2 = 0.3213$. Isso significa que **32.1%** da variabilidade total nas notas de Matemática (nesta amostra) pode ser explicada pela variação nas notas de Língua Portuguesa. Trata-se de um poder explicativo moderado.

Interpretação do Coeficiente (β_1): O coeficiente angular $\beta_1 = 0.52$ indica que, em média, para cada 1 ponto adicional que um aluno obtém em Língua Portuguesa, espera-se um aumento de 0.52 pontos em sua nota de Matemática.

3.2 Análise H2 - O Impacto do Nível Socioeconômico (INSE) na Matemática

Investigamos se o Nível Socioeconômico (INSE) do aluno (variável independente) pode explicar o desempenho em Matemática (variável dependente).

3.2.1 Resultados Obtidos




Figure 2: Relação entre INSE e Proficiência em MT

O **Coefficiente de Correlação (r)** foi de **0.1968**. Este valor indica uma correlação linear positiva fraca, mostrando praticamente uma ausência de relacionamento entre o INSE e a proficiência em Matemática. Para quantificar essa relação, ajustamos o seguinte modelo de regressão linear:

$$Nota_{MT} = 220.6 + 9.88 \cdot (INSE)$$

3.2.2 Interpretação dos Resultados

Poder Explicativo (R^2): O Coeficiente de Determinação foi de $R^2 = 0.0387$. Isso significa que **3.9%** da variabilidade total nas notas de Língua Portuguesa (nesta amostra) pode ser explicada pela variação no Erro Padrão da proficiência. Trata-se de um poder explicativo moderado.

Interpretação do Coeficiente (β_1): O coeficiente angular $\beta_1 = 9.88$ indica que, em média, para cada 1 ponto adicional no Erro Padrão da Proficiência em LP, espera-se uma redução de 9.88 pontos em sua nota de Língua Portuguesa.

3.3 Análise H3 - Relação Incerteza-Proficiência em Matemática

Investigamos se o Erro Padrão da Proficiência em Matemática (variável independente) pode explicar o desempenho efetivo nessa mesma disciplina (Proficiência em MT - variável dependente).

3.3.1 Resultados Obtidos




Figure 3: Relação entre Erro Padrão MT e Proficiência MT

O **Coefficiente de Correlação (r)** foi de **-0.8278**. Este valor indica uma correlação linear negativa forte entre as duas variáveis, demonstrando uma grande dependência entre as variáveis e sendo uma correlação negativa, aponta uma regressão linear decrescente. Para quantificar essa relação, ajustamos o seguinte modelo de regressão linear:

$$Nota_{MT} = 424.67 - 4.93 \cdot (\text{Erro Padrão MT})$$

3.3.2 Interpretação dos Resultados

Poder Explicativo (R^2): O Coeficiente de Determinação foi de $R^2 = 0.6853$. Isso significa que **68.5%** da variabilidade total nas notas de Matemática (nesta amostra) pode ser explicada pela variação no Erro Padrão da proficiência. Trata-se de um poder explicativo moderado a alto, sendo o maior valor de R^2 encontrado nas hipóteses analisadas.

Interpretação do Coeficiente (β_1): O coeficiente angular $\beta_1 = -4.93$ indica que, em média, para cada 1 ponto adicional no Erro Padrão da Proficiência em MT, espera-se uma redução de 4.93 pontos em sua nota de Matemática.

4 Conclusão

Este relatório realizou uma análise estatística descritiva dos microdados do SAEB 2023, utilizando uma amostra de 50.000 alunos do Ensino Médio, para investigar quatro hipóteses centrais sobre o desempenho acadêmico.

Os resultados confirmaram descritivamente todas as hipóteses levantadas:

- **H1 (Interdisciplinaridade):** Foi confirmada uma correlação positiva moderada ($r = 0.5668$) entre as proficiências de Língua Portuguesa e Matemática. O modelo de regressão linear simples indicou que o desempenho em LP explica 32.1% ($R^2 = 0.3213$) da variação nas notas de Matemática.
- **H2 (Fator Socioeconômico):** Confirmou-se que o INSE tem uma relação positiva com o desempenho em Matemática ($r = 0.1968$). Embora estatisticamente significativa, a capacidade explicativa do INSE isoladamente é limitada ($R^2 = 0.0387$), sugerindo que, embora relevante, o INSE é apenas um dos múltiplos fatores que compõem o desempenho.
- **H3 (Relação Incerteza-Proficiência):** A análise mais forte deste estudo foi a H3. Foi encontrada uma correlação negativa forte para MT ($r = -0.8278$) entre o Erro Padrão da nota e a Proficiência em Matemática.

O poder explicativo do Erro Padrão sobre a nota de Matemática (H3) foi o maior identificado ($R^2 = 0.6853$), indicando que 68.5% da variação na nota de MT pode ser explicada pela sua própria incerteza estatística. Na prática, isso demonstra que alunos com baixo desempenho não apenas têm notas baixas, mas suas medições são acompanhadas de maior incerteza no contexto de matemática.

Em suma, esta análise descritiva valida que o desempenho em Matemática está positivamente associado ao domínio da leitura (LP) e ao nível socioeconômico (INSE), ao mesmo tempo que está fortemente e inversamente relacionado à incerteza da própria medição.